

家庭电力消耗多变量时间序列预测实验报告

基于 LSTM、Transformer 与 CNN-Transformer 的多变量时间序列预测

姓名	魏宪正	学号	20255227057
团队人数	1 人	贡献比例	100%
研究领域	大模型、RAG、Agent、多模态	GitHub	https://github.com/longevitywxz/machaintest

本人独立完成数据处理、模型实现、实验训练、结果分析、图表绘制和报告撰写。完整代码、实验结果与最终 PDF 均已提交到 GitHub 仓库。

1. 问题介绍

本项目研究家庭电力消耗预测问题。数据来自 UCI Individual Household Electric Power Consumption，原始记录以分钟为粒度，包含全屋有功功率、无功功率、电压、电流以及三个子表能耗。

实验将分钟数据汇总为日级数据：global_active_power、global_reactive_power 与三个 sub_metering 变量按天求和，voltage 和 global_intensity 按天求平均，并补充 sub_metering_remainder、日期周期特征以及 data.gouv / Meteo-France 92 省月度天气变量。

预测任务为使用过去 90 天的多变量序列预测未来总有功功率曲线，分别设置 90 天短期预测和 365 天长期预测。两种预测长度分别训练模型，评价指标为 MSE 和 MAE。每个模型重复 5 个随机种子实验，并报告均值和标准差。

2. 模型

2.1 LSTM

LSTM 将 90 天多变量序列按时间步输入循环网络，使用最后一层隐藏状态作为历史用电模式的表示，再通过全连接层直接输出未来 horizon 天预测序列。

2.2 Transformer

Transformer 首先将每日特征投影到隐藏维度并加入正弦位置编码，随后使用多头自注意力编码历史序列，最后取末时间步表示输出未来曲线。

2.3 改进模型：CNN-Transformer

CNN-Transformer 先用一维卷积提取局部用电波动，再输入 Transformer 建模长期依赖，最后使用均值池化与末状态门控融合输出预测。

```
Input: X in R^(90 x d), horizon H in {90, 365}
Z = GELU(Conv1D(X, kernel=5))
Z = GELU(Conv1D(Z, kernel=3))
E = TransformerEncoder(PositionalEncoding(Z))
c_mean = MeanPool(E)
c_last = E[-1]
gate = Sigmoid(W_g c_last + b_g)
y_hat = Linear(LayerNorm(c_mean * gate))
Output: y_hat in R^H
```

```
90-day multivariate input
-> 1D CNN local filters
-> positional encoding
-> Transformer encoder
-> mean pooling + last-state gate
-> 90-day / 365-day power forecast
```

3. 结果与分析


模型	预测长度	MSE 均值	MSE 标准差	MAE 均值	MAE 标准差
cnn_transformer	90	129159.24	7296.47	290.40	4.69
cnn_transformer	365	183649.82	5896.00	317.89	5.95
lstm	90	133342.45	5376.87	287.71	6.18
lstm	365	201265.69	11677.71	334.29	10.12
transformer	90	129397.17	10390.95	288.89	15.06
transformer	365	187903.01	1407.90	319.38	3.96

从结果看，90 天预测比 365 天预测更容易保持趋势和幅值稳定；长期预测需要跨季节建模，误差更大。CNN-Transformer 在 365 天长期预测上优于 LSTM，并接近 Transformer；在 90 天预测中 MSE 接近 Transformer，但 MAE 略高。

该现象说明卷积层提取的局部平滑特征有助于长期趋势建模，但也可能削弱短期尖峰拟合。家庭用电序列存在较强随机性，直接用日级序列预测 365 天会使模型更倾向于学习平滑趋势，而难以恢复真实曲线中的高频波动。


CNN-Transformer 的优势来自卷积预先整合邻近日子的局部模式，以及均值池化与最后状态门控对整体趋势和最近状态的融合。不足是月度天气变量粒度较粗、样本数量有限，模型在短期任务上容易过平滑。

图 1 LSTM 90 天预测




蓝色为真实值 Ground Truth，橙色为模型预测曲线。

图 2 Transformer 90 天预测




蓝色为真实值 Ground Truth，橙色为模型预测曲线。

图 3 CNN-Transformer 90 天预测




蓝色为真实值 Ground Truth，橙色为模型预测曲线。

图 4 LSTM 365 天预测




蓝色为真实值 Ground Truth，橙色为模型预测曲线。

图 5 Transformer 365 天预测



蓝色为真实值 Ground Truth，橙色为模型预测曲线。

图 6 CNN-Transformer 365 天预测



蓝色为真实值 Ground Truth，橙色为模型预测曲线。

4. 讨论

本实验采用直接多步预测，避免递归误差累积，但要求模型一次性学习完整未来曲线。日期周期特征提供星期和月份信息，天气特征提供降水和雾等外部环境信息，有助于模型拟合生活规律、季节性变化和气候影响。

后续改进可以加入更细粒度的逐日气象、节假日和异常用电标记，也可以采用趋势-残差分解或多尺度卷积来改善尖峰预测。本报告撰写过程中使用了 ChatGPT/Codex 辅助整理文字和代码结构；模型设计、实验运行与结果分析以仓库中的可复现实验输出为准。

参考文献

- [1] UCI Machine Learning Repository. Individual household electric power consumption.
- [2] data.gouv / Météo-France. Données climatologiques de base mensuelles.
- [3] Vaswani, A. et al. Attention Is All You Need. NeurIPS, 2017.
- [4] Hochreiter, S., Schmidhuber, J. Long Short-Term Memory. Neural Computation, 1997.
- [5] 课程作业说明《2026年专硕机器学习课程项目》。