

# 家庭电力消耗多变量时间序列预测实验报告

## 作者信息

姓名：魏宪正；学号：20255227057；团队人数：1 人。

所属研究领域：大模型、RAG、Agent、多模态。

贡献分工：本人独立完成数据处理、模型实现、实验训练、结果分析、图表绘制和报告撰写，贡献比例 100%。

## 1. 问题介绍

本项目研究家庭电力消耗预测问题。数据来自 UCI Individual Household Electric Power Consumption，原始记录以分钟为粒度。实验将分钟数据汇总为日级数据：功率与子表能耗按天求和，电压和电流按天求平均，并补充 sub\_metering\_remainder、日期周期特征和 data.gouv / Meteo-France 92 省月度天气变量。

预测任务为使用过去 90 天的多变量序列预测未来总有功功率曲线，分别设置 90 天短期预测和 365 天长期预测。两种预测长度分别训练模型，评价指标为 MSE 和 MAE。每个模型重复 5 个随机种子实验。

## 2. 模型

### 2.1 LSTM

LSTM 使用最后一层隐藏状态表示历史用电模式，再通过全连接层直接输出未来 horizon 天预测序列。

### 2.2 Transformer

Transformer 使用多头自注意力编码 90 天历史序列，并以最后时间步表示输出未来曲线。

### 2.3 改进模型：CNN-Transformer

CNN-Transformer 先用一维卷积提取局部用电波动，再输入 Transformer 建模长期依赖，最后使用均值池化与门控融合输出预测。

## 结构伪代码

```
Input  $X$  in  $\mathbb{R}^{(90 \times d)}$ ;  $Z = \text{GELU}(\text{Conv1D}_{k5}(X))$ ;  $Z = \text{GELU}(\text{Conv1D}_{k3}(Z))$ ;  $E =$   
 $\text{TransformerEncoder}(\text{PositionalEncoding}(Z))$ ;  $c = \text{MeanPool}(E) * \text{Sigmoid}(W_g E_{\text{last}} + b_g)$ ;  $y_{\text{hat}} =$   
 $\text{Linear}(\text{LayerNorm}(c))$ .
```

结构流程：90 天多变量输入  $\rightarrow$  1D CNN 局部滤波  $\rightarrow$  位置编码  $\rightarrow$  Transformer 编码  $\rightarrow$  均值池化与末状态门控  $\rightarrow$  90/365 天预测。


## 3. 结果与分析

| Model           | Horizon | MSE mean  | MSE std  | MAE mean | MAE std |
|-----------------|---------|-----------|----------|----------|---------|
| cnn_transformer | 90      | 129159.24 | 7296.47  | 290.40   | 4.69    |
| cnn_transformer | 365     | 183649.82 | 5896.00  | 317.89   | 5.95    |
| lstm            | 90      | 133342.45 | 5376.87  | 287.71   | 6.18    |
| lstm            | 365     | 201265.69 | 11677.71 | 334.29   | 10.12   |
| transformer     | 90      | 129397.17 | 10390.95 | 288.89   | 15.06   |
| transformer     | 365     | 187903.01 | 1407.90  | 319.38   | 3.96    |


从结果看，90 天预测比 365 天预测更容易保持趋势和幅值稳定；长期预测需要跨季节建模，误差更大。CNN-Transformer 在 365 天长期预测上优于 LSTM，并接近 Transformer；在 90 天预测中 MSE 接近 Transformer，但 MAE 略高。这说明卷积局部特征有助于长期趋势建模，但也可能削弱短期尖峰拟合。

CNN-Transformer 的优势来自卷积预先整合邻近日子的局部模式，以及均值池化与最后状态门控对整体趋势和最近状态的融合。不足是月度天气变量粒度较粗、样本数量有限，模型在短期任务上容易过平滑。后续可加入逐日气象、节假日和异常用电标记。


## LSTM 90-day




## Transformer 90-day




## CNN-Transformer 90-day




## LSTM 365-day



## Transformer 365-day



## CNN-Transformer 365-day



## 4. 讨论

本实验采用直接多步预测，避免递归误差累积，但要求模型一次性学习完整未来曲线。已加入月度天气变量，后续可加入更细粒度的逐日气象、节假日特征，或先分解趋势与季节项后预测残差。报告撰写使用 ChatGPT/Codex 辅助整理文字和代码结构。

## 参考文献

- [1] UCI Machine Learning Repository. Individual household electric power consumption.
- [2] data.gouv / Meteo-France. Donnees climatologiques de base mensuelles.
- [3] Vaswani, A. et al. Attention Is All You Need. NeurIPS, 2017.
- [4] Hochreiter, S., Schmidhuber, J. Long Short-Term Memory. Neural Computation, 1997.
- [5] 课程作业说明《2026年专硕机器学习课程项目》。